7款AI产品深度测评与产品改进提案：基于3年真实使用的用户视角研究

一. 前言

1.0 声明

本文档为个人独立输出的 AI 产品体验研究成果，所有洞察与结论均基于真实使用场景，仅借助工具提升撰写效率。

1.1 背景陈述

自 2022 年起持续使用各类 AI 产品，至今已有三年完整使用周期。AI 已成为我学习、代码开发、文档处理与日常决策的核心工具。随着使用深度提升，我开始从**产品视角**思考：不同产品的用户留存差异、付费决策逻辑、场景适配能力与体验痛点。基于长期真实使用记录，我对 7 款主流 AI 产品进行系统性跟踪与复盘，将用户体感转化为**可复用的产品洞察与可落地的改进方案**。

1.2 核心结论

经过三年持续使用与深度复盘，我得出一条核心结论：**用户选择 AI 产品的核心并非模型能力强弱，而是场景适配度与不可替代性**。海外头部产品虽具备技术与视野优势，但在我的高频学习、编程、文档等真实场景中，完成效率与体验并不占优；而能够精准解决单一场景痛点、提供稳定闭环体验的产品，反而成为我的高频使用工具。用户真正需要的不是 “全能型 AI”，而是在特定场景下**可靠、高效、能把事办成**的工具型 AI。这也印证了：AI 产品的核心竞争力，是在垂直场景中建立难以替代的用户价值。

1.3 产品洞察

洞察一：用户心智高度场景化，产品使用呈现高度集中特征

用户会对 AI 产品形成清晰的**能力边界认知**，并按场景固定使用习惯，最终呈现 “一款产品占据 80% 使用量、其余产品低频备用” 的结构。一旦用户形成**场景依赖**，迁移成本极高，不会因单纯的 “能力更强” 而轻易替换产品。

洞察二：用户付费的核心是任务完成度，而非模型能力

用户不为参数、概念或技术先进性付费，只为**可落地的任务完成效率**付费。付费决策公式可总结为：**用户价值 = 时间成本降低 + 结果确定性 - 使用成本**。能稳定解决具体问题、提升效率的产品，才能获得付费意愿。

洞察三：核心功能迭代不可逆，破坏用户依赖将直接导致流失

用户对产品的**依赖习惯**一旦形成，便构成核心留存壁垒。若产品下线用户已依赖的核心功能，会直接打断使用链路、破坏用户心智，进而导致用户不可逆流失。迭代应优先保障用户核心价值的连续性。

1.4 改进方案提要：

基于上述用户洞察与体验痛点，本报告提出两项可落地的产品改进方向，均围绕**降低用户决策成本、提升 AI 交互确定性**展开：

方案一：抖音商城“智能购物助手”

针对电商场景信息过载、决策支持不足、AI 能力与购物场景割裂的问题，提出将豆包 AI 能力原生嵌入抖音商城，为用户提供**实时咨询、商品对比、价格参考、决策辅助**的一体化购物体验。依托字节现有产品与数据生态，该方案具备明确的落地可行性。

方案二：AI 交互能力优化（听懂人话 + 减少幻觉）

针对当前 AI 产品普遍存在的**意图理解不足、信息不准确、过度自信输出**等体验痛点，提出三层机制：**意图澄清机制、幻觉检测与校验机制、用户反馈闭环**。通过成熟的产品化手段提升 AI 交互可靠性，让 AI 更贴合真实人类对话习惯。

两项方案共同指向

用户对 AI 的核心诉求并非更强的模型能力，而是**更省心、更可靠、更能办成事**的体验。把 “听懂、可信、有用” 做到极致，才能真正建立用户长期依赖。

1.5 尾声

撰写这份报告的过程，也是我从**高频用户**向**AI 产品经理思维**转变的过程。普通用户关注 “好用 / 不好用” 的体感，而产品经理需要把体感翻译成**用户规律**，把规律落地为**产品方案**，最终用**可落地的设计**解决真实问题。

本次报告以自身 3 年真实使用为样本，完成了三件事：

1. 清晰拆解用户对 AI 产品的**心智定位与使用习惯**；
2. 提炼出用户**付费与留存**的真实逻辑；
3. 从产品迭代案例中总结出**用户价值敬畏**的重要性。

这正是 AI 产品经理日常工作的核心：**洞察用户、定义价值、落地决策**。这份报告是我对 AI 产品的一次完整思考与实践，也代表我希望以用户为中心、做真正解决问题的 AI 产品的初心。

二. 研究方法与用户画像

2.1 研究方法：把自己当成样本

本报告采用**长期定性跟踪 + 单用户深度研究法**，以本人连续 3 年的真实使用行为为样本，对 AI 产品的使用场景、任务完成情况、交互体验、留存动机与付费决策进行结构化记录与复盘。研究过程不依赖问卷或外部数据，而是通过沉浸式使用、定期体验复盘，将真实用户体感转化为可复用的产品洞察，确保结论具备场景真实性与用户视角参考价值。

2.2 用户画像：我是一个什么样的用户

1. **身份**：人工智能与自动化学院在读学生，高频使用 AI 完成学习、代码开发、文档处理、课设与日常决策。
2. **核心使用场景**：
   a. 学习与研究：英文论文阅读、专业 PPT 制作、代码编写与调试、课程设计；
   b. 生活与决策：生活攻略查询、常识咨询、文档处理、信息验证；
   c. 体验与探索：AI 新产品体验、功能验证与趋势观察。
3. **使用习惯**：实用主义导向，按场景固定使用产品，不盲目追求参数与热度，重视效率与确定性。
4. **付费倾向**：对价格敏感，但愿意为**可落地的任务完成效率**付费，不为技术概念或品牌溢价买单。

2.3 这份画像的意义

本研究以单一深度用户为样本，虽不具备大规模统计意义，但能够还原用户在真实场景下的**决策心理、使用链路、痛点感受与价值判断**，这类细节是传统后台数据难以捕捉的。作为学生用户与 AI 深度使用者，本画像代表了 AI 产品的核心潜在用户群体，其洞察对产品体验优化、场景化设计具备真实参考意义。

第三章：7款AI产品的真实使用记录与剖析

3.1 使用总览

产品	类型	使用频率	付费状态	推荐他人	我的定位
Deepseek	对话助手	每天	免费	是	主力：复杂问题/编程/决策
豆包	对话助手	每周	免费	是	辅助：生活攻略/PDF/轻量问答
ChatGPT	对话助手	每周	曾付费，准备停	否	边缘：偶尔开眼界用
Cursor	编程工具	每月	付费	否	辅助：编程攻坚

Copilot	编程工具	弃用	教育免费	是	弃用：不会干活
智谱轻言	对话助手	弃用	免费	否	弃用：删了核心功能
Sora	图像生成	弃用	内测试用	是	弃用：不是目标用户

通过上表 7 款产品的整体使用情况可以看出，我的 AI 产品使用呈现**高度场景化、集中化、实用主义**特征。本章将按照 “核心主力产品→中外产品对比→工具型产品对比→典型流失案例” 的逻辑展开分组复盘，所有分析均围绕一个核心视角：**用户为何留存？为何付费？为何弃用？**

通过对比分析，可提前得出本章核心结论：**AI 产品的竞争力，从来不在于模型能力强弱，而在于是否精准匹配用户场景、是否能稳定完成任务、是否能持续提供不可替代的用户价值。**脱离场景谈能力、脱离完成度谈体验，最终都会导致用户流失。

3.2 留存产品对比分析：Deepseek & 豆包

Deepseek 与豆包是我所有 AI 产品中**留存时间最长、使用频率最高**的两款产品，二者并非竞争关系，而是形成了**一深一浅、一慢一快**的互补结构，共同构成我日常 AI 使用的核心体系，核心共性的是：均满足场景不可替代性 + 任务完成确定性，这也是其长期留存的关键。

3.2.1 核心差异对比

对比维度	Deepseek	豆包
产品定位	慢脑 / 深度思考型助手	快脑 / 即时效率型助手
核心目标	追求严谨、可落地、可同步思考	追求速度、闭环、不打断用户流程
高频使用场景	学习、编程、课设、复杂逻辑拆解、深度讨论、文档框架搭建	生活查询、快速问答、PDF/PPT 多模态处理、
体验亮点	1. 逻辑严密、推导不跳步；2. 代码可直接运行；3. 支持多轮深度辩论，能跟上思考节奏	1. 多模态闭环极强，PDF/PPT 无需跳转；2. 交单；3. 响应极快，即时给出答案
核心短板	多模态处理能力一般，PDF/PPT 需跳转第三方	长期上下文记忆较弱，不适合复杂深度推理

3.2.2 共同留存原因

1. 场景适配度极高：精准匹配我的核心使用场景，无明显替代产品，形成场景绑定；
2. 任务完成确定性强：能稳定解决对应场景的问题，不瞎编、不敷衍，交付感足；
3. 体验无明显硬伤：短板均不影响核心场景使用，不会出现 “用着闹心” 的情况。

3.2.3 产品启示

1. AI 产品的核心竞争力不是 “全能” ，而是**在特定场景里做到足够深、足够稳**，精准匹配用户需求；
2. 用户会自然给 AI 划分能力边界，形成稳定使用心智，一旦建立习惯，迁移成本极高；

3. 留存的关键的是 “不可替代性”，而非 “能力最强”，互补型产品可共同占据用户心智，实现长期留存。

3.3中外 AI 模型对比：Deepseek vs ChatGPT

本小节通过对比海外头部模型与国内优质模型，分析**技术能力≠用户价值**，进一步验证：用户留存与付费的核心是**场景匹配度**，而非单纯技术强弱。

3.3.1核心差异对比

对比维度	Deepseek	ChatGPT
产品定位	深度思考型通用 AI 助手	全球视野型通用 AI 助手
知识与能力	中文逻辑扎实、工科思维强、落地性好	知识广度高、英文资源丰富、全球化视角
我的核心场景	代码编写、逻辑推导、课程设计、结构化写作	英文辅助、海外信息查阅、拓展思路
体验亮点	逻辑严谨、步骤清晰、代码可直接运行、贴合国内用户习惯	知识覆盖广、创作自由度高、英文场景优
付费情况	免费即可满足核心需求	曾付费，现已停止续费
弃用 / 低频原因	—	性价比不足、边际价值低、与核心场景匹

3.3.2关键结论

1. **ChatGPT 能力虽强，但并非不可替代**在我高频使用的**代码、逻辑、中文写作**场景中，没有体现出足够的碾压性优势。
2. **用户不为 “更强” 付费，只为 “更适配” 付费**对我而言，Deepseek 免费提供的**落地能力、任务完成度**，已经超过 ChatGPT 付费带来的价值。
3. **性价比直接决定留存**当付费带来的边际体验提升，不足以覆盖成本时，用户会果断停止付费。

3.3.3 产品启示

1. AI 产品竞争的核心，不是**参数与技术炫技**，而是**真实场景下的任务完成效率**。
2. 海外产品在国内市场的核心挑战，不是能力不足，而是**场景适配与性价比**问题。
3. 用户非常清醒：只对 “能帮自己办成事” 的产品买单，不为概念或品牌溢价买单。

3.4 编程 AI 工具对比：Cursor vs GitHub Copilot

本小节通过两款编程类 AI 产品的对比，验证：**用户留存与付费的唯一标准，是任务完成度**。

3.4.1 核心差异对比

对比维度	Cursor	GitHub Copilot
产品定位	面向完整开发任务的 AI 编程助手	代码片段补全工具
核心能力	完整代码生成、错误定位、逻辑修改、可直接运行	单行 / 局部代码补全、语法提示
我的使用场景	课程设计、代码调试、完整功能实现	简单代码补全、语法参考
体验亮点	理解完整需求、输出可落地代码、解决实际问题	集成方便、基础补全速度快
核心短板	—	无法处理复杂逻辑、难以独立完成任务
使用与付费	高频使用，**主动付费**	免费教育版，**已弃用**

3.4.2 关键结论

1. **Cursor 能真正解决问题，所以我愿意付费**它可以独立完成一段代码、帮我定位 bug、优化逻辑，大幅降低开发成本，**交付感极强**。
2. **GitHub Copilot 只做补全，无法满足真实需求**只能做碎片式提示，不能支撑完整任务，**用起来效率反而更低**。
3. **付费与留存，只由 “能不能办成事” 决定**免费不代表有竞争力，有用才是用户的核心决策依据。

3.4.3 产品启示

1. 工具型 AI 的核心壁垒，是**任务完成度与确定性**，而不只是功能堆砌。
2. 用户愿意为**真正省时间、解决痛点**的产品付费，不为 “听起来厉害” 买单。
3. 只做浅层辅助、无法独立支撑任务的 AI，很容易被替代或抛弃。

3.5 流失案例分析

本小节通过智谱轻言的流失案例，重点分析：**核心功能迭代不可逆，破坏用户依赖将直接导致用户流失**，这也是 AI 产品迭代过程中需重点规避的核心问题。

3.5.1 产品核心信息与使用概况

对比维度	智谱轻言
产品定位	曾具备独家数据处理能力的通用 AI 助手
核心能力（流失前）	上传数据→自动写代码→自动运行→自动纠错→输出结果（全程无需用户干预）
我的使用场景	数据处理、自动化分析、无需手动操作的高效任务完成
体验亮点（流失前）	独家自动化数据处理能力，能真正 “代用户干活”，形成强依赖
核心短板（流失前）	非核心功能体验一般，但不影响核心场景使用
使用状态	曾高频使用、形成强依赖，后因核心功能下线，**彻底弃用**

3.5.2 流失核心原因（关键重点）

1. 核心功能被直接下线：流失前最核心的 “自动数据处理 + 代码执行” 功能，改版后完全移除，没有替代方案，**用户使用理由彻底消失**。
2. 用户依赖被强行打破：该功能是我选择智谱轻言的唯一原因，长期使用已形成固定习惯，核心功能缺失后，使用链路断裂，无法满足我的核心需求。
3. 无任何过渡与补偿：功能下线前无通知、下线后无替代功能推荐，用户体验极差，没有任何留存理由。

3.5.3 产品启示

1. 核心功能是用户留存的 “生命线”，一旦用户形成依赖，**核心功能迭代必须谨慎，不可轻易下线**，否则会直接导致用户不可逆流失。
2. 用户对产品的 “依赖”，本质是对 “核心价值” 的依赖，而非对产品本身的喜欢，失去核心价值，用户会果断迁移。
3. 产品迭代需敬畏用户习惯，若必须调整核心功能，需提前通知用户、提供替代方案，降低用户迁移成本，避免直接流失

3.6 非目标用户案例：Sora2

本小节通过 Sora 的使用体验，说明：**AI 产品再强，脱离目标用户场景，也无法形成留存。**

3.6.1 产品核心信息与使用概况

对比维度	Sora
产品定位	文生视频领域的顶尖 AI 模型
核心能力	文本生成高质量视频、画面细节与连贯性极强
我的使用场景	仅初期体验、无真实高频需求
体验亮点	技术能力顶尖、生成效果远超同类产品
核心问题	与我的学习、代码、文档等核心场景完全无关
使用状态	短期尝鲜后，**长期弃用**

3.6.2 弃用核心原因

1. **并非目标用户**我的日常需求集中在学习、编程、文档处理、逻辑思考，几乎没有视频生成需求。
2. **能力再强，与我无关**技术领先不代表对我有价值，产品能力与个人场景完全不匹配。
3. **无持续使用动机**没有必须打开它的理由，新鲜感一过，自然不再使用。

3.6.3 产品启示

1. AI 产品的价值，**必须绑定具体用户与真实场景**，脱离场景谈技术没有意义。
2. 不是 “产品越强，用户越多”，而是**越精准匹配目标用户，留存越强**。
3. 盲目追求全能、炫技，不如深耕目标用户的核心场景，建立不可替代性。

3.7 本章总结

本章通过对 7 款 AI 产品的分组对比、留存与流失案例剖析，结合本人 3 年真实使用体验，汇总核心结论与产品规律，进一步验证前文提出的产品洞察，为后续 AI 产品改进方案提供真实用户视角支撑，具体总结如下：

1. 留存核心：AI 产品的长期留存，**不取决于模型能力强弱，而取决于场景匹配度、任务完成确定性与不可替代性**。Deepseek、豆包、Cursor 的留存案例均证明，精准贴合用户核心场景、能稳定解决实际问题，是用户长期使用的关键。
2. 流失逻辑：用户弃用 AI 产品，本质是 “价值断裂” —— 要么是核心功能被破坏（智谱轻言），要么是与自身场景无关（Sora），要么是无法满足真实任务需求（GitHub Copilot），要么是性价比不足（ChatGPT），核心都是 “无法持续提供用户需要的价值”。
3. 核心启示：AI 产品的竞争，核心是 “场景深耕” 而非 “全能炫技”；用户决策的核心，是 “有用、省心、能办成事” 而非 “技术先进”；产品迭代的核心，是 “敬畏用户依赖、守住核心价值” 而非 “盲目优化”。

本章所有分析均基于真实用户体验，既还原了普通用户对 AI 产品的使用心智与决策逻辑，也为 AI 产品的场景设计、功能迭代、留存运营提供了可参考的用户视角，为后续提出可落地的改进方案奠定基础。

四. 完整改进方案

4.0 用户核心痛点与根因总结

结合第三章 7 款产品的真实使用体验，提炼出当前 AI 产品及抖音商城场景下的 3 个核心痛点，也是本次改进方案的核心出发点，具体如下：

1. 电商场景决策痛点：抖音商城商品繁多、信息过载，用户难以快速筛选、对比，缺乏个性化 AI 决策辅助，导致决策成本高、转化率低（根因：AI 能力与电商场景割裂，未形成原生协同）；
2. AI 交互痛点：当前 AI 普遍存在 “听不懂用户模糊需求、过度自信输出幻觉、不会主动追问补全需求” 的问题，导致交互效率低、用户信任度不足（根因：缺乏意图澄清机制与幻觉校验机制）；
3. 价值匹配痛点：AI 能力与用户真实场景、核心需求脱节，要么能力冗余（如 Sora），要么无法解决实际问题（如 Copilot），未实现 “能力→价值” 的转化（根因：产品设计未以用户任务完成为核心）。

4.1 抖音商城的“智能购物助手”

4.1.1 问题拆解：购物选择困难症

上周想买个裤子，预算300左右，想挑一些立体的材质。打开抖音商城，我面对的是：

几千条商品、几十个品牌、一堆看不懂的参数、分不清哪些是广告哪些是真实推荐。我得自己筛价格、自己看参数、自己翻评论、自己比哪家更靠谱。一套操作下来，半小时过去了，最后选了一个——但我真的选对了吗？我不知道。

这不是我的问题，这是移动端购物到现在还没解决好的问题：**信息过载，但决策支持不够。**

抖音商城的内容形式已经很丰富了，有短视频、有直播、有图文、有评价。但这些东西是“给”用户看的，不是“帮”用户想的。我需要的是有人帮我梳理、帮我对比、帮我决策——在PC时代，我会开十几个网页比价；在移动时代，我只能来回切App、来回翻评价、来回记参数。

更麻烦的是，抖音商城现在没有“比价”功能。我想知道同一款耳机在不同店铺卖多少钱，得自己搜、自己记、自己算。这个耳机比那个贵在哪？这个店铺评分高但价格也高，值不值？这些问题，都得我自己想。

最荒诞的是：抖音有豆包，豆包已经在做AI购物了。但豆包是独立的App，我要买东西，得从抖音切到豆包，在豆包里聊完，再切回抖音下单。又回到了“搬运”的老路上。

豆包App近期正在内测购物下单功能，用户可以通过对话让豆包推荐商品，然后直接在豆包内完成支付。技术已经到位了，豆包大模型2.0的多模态理解能力可以处理复杂的购物指令，进行任务拆解和实时比价。阿里千问已经做到了“一句话点奶茶、订机票”，京东也上线了AI购物功能。但抖音商城移动端本身，还没有一个原生的智能购物助手。

4.1.2 核心痛点

用户端：抖音商城商品同质化严重，筛选、对比耗时；面对复杂需求（如 “学生党百元内平价护肤品，敏感肌适用”），现有搜索无法精准匹配，决策效率低；

平台端：AI 能力与商城场景割裂，豆包的多模态、问答能力未被充分利用，无法通过 AI 提升用户停留时长、转化率与复购率。

4.1.3 用户体感：我想要的是这样的

我想要的是：在抖音商城看商品的时候，旁边有一个“购物助手”，我可以随时问它。

看耳机的时候，直接问它：“这个耳机和我刚才看的那个漫步者比，哪个音质好？”

它知道“刚才看的那个”是哪个，不用我重新搜、重新找。它能把两款耳机的参数拉出来对比，能告诉我评价里大家怎么说，能提醒我“这个价格比上个月贵了50块”。

选尺码的时候，直接问它：“我平时穿42码运动鞋，这款应该买多大？”

它能根据我过去的购买记录、根据这款鞋的尺码偏差评价，给我一个靠谱的建议。

犹豫要不要买的时候，直接问它：“这个值得买吗？有没有更划算的替代？”

它能告诉我同类产品的价格分布，能提醒我“这款明天可能降价”，能说“这个牌子这个型号口碑不太好，建议看看另一个”。

甚至，我不用主动问它。我看了几款商品没下单，它可以说：“看你看了几款运动相机，需要我帮你比一下参数吗？”

这就是我想要的——**一个比我更懂购物、但听我指挥的助手**。

4.1.4 解决方案

方案A：抖音商城内置“购物助手”入口（最快落地）

在抖音商城的搜索框旁边、商品详情页下方、购物车页面，都加一个“问助手”的入口。用户点击后，唤起购物助手，可以直接用语音或文字提问。

核心要解决的是“上下文理解”——用户刚看过什么商品、在哪个页面问的、问的是什么问题，助手要能理解。这需要和商城的前端页面打通，记录用户的浏览行为（当然要合规、要授权）。

技术底座是现成的，豆包大模型已经在做了。豆包能实现“意图识别—商品推荐—配置选择—支付完成”的全链路闭环，那把这个能力搬到抖音商城里面，技术上完全可行。

方案B：多商品对比能力（体验核心）

这是购物决策最需要的功能，也是现在最缺失的。

当用户问“A和B哪个好”的时候，助手应该能自动拉出一个对比页——参数对参数、价格对价格、评价对评价。用户可以在这个对比页上勾选、划掉、继续加商品进来比。

对比不是简单的并列，是要有结论的。助手可以说“从参数看A更好，但评价里很多人说B续航更久，看你更在意哪个”。

方案C：价格追踪与提醒（粘性功能）

用户看到一款商品，可以问助手“这个价格怎么样”。助手能给出价格走势、历史最低、比同类贵还是便宜。

用户也可以设置提醒：“这个降到300以下告诉我”。助手后台监控，降了就给用户推消息。

这个功能不需要复杂的谈判，抖音商城自己的数据就能做。

方案D：个性化推荐穿透明化（信任建设）

现在用户对推荐机制的信任度不高，因为不知道“为什么推这个”。

购物助手可以解释：推这个是因为你上次买了同类产品、因为和你相似的用户好评多、因为这个现在有活动。把推荐的理由说出来，用户反而更愿意接受。

4.1.5 核心指标

指标类型	具体指标	目标值	统计周期
用户端指标	AI 助手使用率	≥30%（使用商城的用户中，30% 会触发 AI 助手）	周统计
用户端指标	决策时长降低率	≥40%（使用 AI 助手的用户，比未使用用户的下单决策时长降低 40%）	周统计
用户端指标	用户满意度	≥85 分（100 分制，通过下单后弹窗调研）	月统计
平台端指标	商城转化率提升	≥15%（使用 AI 助手的用户，下单转化率比未使用用户提升 15%）	周统计
平台端指标	用户停留时长提升	≥20%（使用 AI 助手的用户，商城停留时长比未使用用户提升 20%）	周统计
产品端指标	AI 需求解析准确率	≥90%（AI 拆解用户需求与用户真实需求的匹配度）	日统计

4.1.6 评价体系

1. 用户体验维度（权重 40%）

- 需求解析准确率（30 分）：按每日统计数据，达标得满分，每低 1% 扣 1 分；
- 用户满意度（40 分）：月调研得分≥85 分得满分，每低 1 分扣 2 分；
- 交互流畅度（30 分）：无卡顿、无跳转、响应时长≤1 秒，出现异常一次扣 5 分。

2. 业务价值维度（权重 40%）

- 转化率提升（40 分）：达标得满分，每低 1% 扣 2 分；
- 停留时长提升（30 分）：达标得满分，每低 1% 扣 1.5 分；
- AI 使用率（30 分）：达标得满分，每低 1% 扣 1 分。

3. 产品落地维度（权重 20%）

- 功能稳定性（10 分）：无故障运行率≥99.9%，每出现一次故障扣 2 分；
- 迭代优化效率（10 分）：根据用户反馈，每周完成 1-2 个小优化，未达标扣 3-10 分。

4.1.7 产品价值

对用户：降低购物决策成本，解决 “选品难、对比难” 的痛点，获得个性化、高效的购物体验；

对平台：实现豆包 AI 与抖音商城的原生协同，提升商城核心业务指标（转化率、停留时长），强化字节生态的产品竞争力；

对 AI 产品：让豆包的能力落地到具体电商场景，实现 “AI 能力→用户价值→平台价值” 的闭环。

4.1.8 优先级建议

P0：抖音商城内置购物助手入口，让用户在购物场景里能直接唤起AI。这是体验的起点。

P1：多商品对比能力和价格追踪。这两个是用户购物决策最核心的痛点，也是最能体现“智能”的地方。

P2：个性化推荐透明化和跨品类智能推荐。这些是体验加分项，但不是刚需。

4.1.9 为什么这个方案现在有意义

豆包已经在做AI购物了，千问已经跑通了“对话即交易”的路径，京东也上线了AI购物。这说明AI电商不是“要不要做”的问题，是“怎么做”的问题。

抖音商城现在的优势是用户量大、商品丰富、内容形式多。劣势是用户购物决策还停留在“自己看、自己比、自己想”的阶段。把这个劣势补上，就是机会。

而且，这个方案不需要等别人开放接口，不需要谈合作——都是字节自己的产品，从豆包到抖音商城，从技术到数据，都是现成的。问题不是“能不能做”，是“想不想做”。

从用户视角看，这很简单：**我买东西的时候，想要一个能帮我选的助手**。

4.2 方案二：让AI学会“听懂人话”和“知道自己错了”

4.2.1 问题拆解：两个让用户崩溃的瞬间

第一个瞬间：我说的话，AI听不懂。

我问“帮我找个适合在实验室戴的耳机，不要太吵”。我想的是：实验室有噪音，需要降噪好的；旁边有人说话，不能漏音；长时间戴，要舒服。但AI听到的是“耳机”“不要吵”，然后给我推荐了一堆“音质好”的——那是给听歌的人用的，不是给实验室用的。

这不是AI笨，是我没说清楚。但问题是，真人之间说话本来就不需要说清楚。我跟室友说“实验室那个耳机”，他懂；我跟AI说同样的话，它不懂。因为AI没有和我共享那个“上下文”——实验室是什么环境、我平时用什么设备、我上次说过什么。

第二个瞬间：AI说得太自信，我被骗了。

问它某个开源项目的地址，它给我一个，我点开，404。问它某段代码能不能这样写，它说可以，我跑起来，报错。问它某个论文有没有中文翻译，它说有，我找了半天，没有。

每一次被骗，都是对信任的一次消耗。消耗到最后，我学会了一件事：AI给的信息，都得自己验证一遍。那问题来了——如果我都得自己验证，我要AI干嘛？

这不是“幻觉”的问题，这是“表达方式”的问题。幻觉短期内解决不了，但AI可以学会两件事：第一，听不懂的时候追问；第二，不确定的时候承认。

4.2.2 核心痛点

意图理解不足：用户输入模糊需求（如 “帮我写个课设代码”），AI 无法精准判断具体需求（哪种课设、哪种语言），输出内容偏离用户预期；

幻觉输出严重：AI 对不确定的问题，过度自信输出错误信息（如错误代码、错误知识点），导致用户信任度下降；

缺乏追问机制：当用户需求不明确时，AI 不会主动追问补全，而是盲目输出，降低交互效率。

4.2.3 用户体感：我想要的是这样的

我想要的是这样的：

当我说“帮我找个适合在实验室戴的耳机”，AI不会直接给答案，而是问：“实验室环境需要降噪吗？还是需要不漏音怕影响别人？你平时用手机还是电脑听？”——它用自己的追问，把我没说出来的需求挖出来。

最新的研究已经证明了这条路可行。Salesforce和UIUC的团队提出了UserBench框架，专门用来评估AI在交互中理解用户隐式偏好的能力。他们发现，用户在真实对话中往往不会一次性说清楚所有需求，而是用“行程很紧”这种话暗示“要直飞”。主流模型能通过主动对话挖掘到的用户偏好不到30%，说明AI“听懂人话”这件事还有巨大的提升空间。

当我说“这个项目地址给我”，如果AI不确定，它应该说：“我记得有个叫xxx的项目，但不记得地址了，建议你搜一下xxx关键词，或者我可以去网上帮你查一下再给你。”

当我说“这段代码能这样写吗”，如果AI没把握，它应该说：“理论上可以，但我没见过这么用的，建议你跑一下测试，或者我可以先帮你生成一个测试用例。”

当AI给出信息的时候，它能主动标注来源：“这个信息来自某篇文章”“这是根据记忆给出的”“这是推理得出的”。我扫一眼就知道，哪个是靠谱的，哪个需要验证。

甚至更高级一点：AI自己跟自己辩论。

北大的研究团队提出了一种基于马尔可夫链的多智能体辩论框架，给AI设了三个角色——一个Trust（信任者）、一个Skeptic（怀疑者）、一个Leader（裁决者）。它们针对同一个问题来回辩论，直到达成共识或者轮数用完。实验结果证明，这种“自己跟自己吵架”的方式，能显著提高幻觉检测的准确率。

更轻量级的方案是NabaOS框架。它给每个工具调用都生成一个带签名的“执行收据”，AI没法伪造。然后系统会把AI回答里的每个claim和这些收据一一核对，发现对不上的就标记出来。整个过程只需要15毫秒，但能检测出94.2%的虚假工具调用。

4.2.4 解决方案：三层架构的“清醒AI”

方案A：意图澄清层——让AI学会追问

这是让AI“听懂人话”的第一步。

当用户输入比较模糊时，AI不急着给答案，而是主动追问。追问不是随便问，是有策略地问：

1. **识别缺失信息**：用户说“推荐耳机”，AI能识别出缺失的关键维度——使用场景、预算、偏好
2. **追问关键维度**：不是把几十个问题全扔给用户，而是先问最重要的两三个
3. **渐进式澄清**：用户回答一个，AI再基于这个回答推下一个问题

阿里云的意图识别解决方案已经证明了这条路可行。他们用Qwen1.5做模型训练，让AI从大量对话数据里学习用户的表达模式，在单意图识别场景能做到90%以上的准确率。关键是训练数据要覆盖尽可能丰富的问法和情境，让AI见过足够多的“人是怎么说话的”。

更深一层是UserRL的训练框架，它把“用户在线交互”这件事本身变成了一个强化学习问题。AI在真实对话中不断试错，做对了有奖励，做错了有惩罚，慢慢就学会了什么时候该追问、什么时候该给答案。

方案B：幻觉检测层——让AI学会怀疑自己

这是让AI“知道自己不知道”的核心。

方案B1：工具执行收据（最快落地）

NabaOS的思路特别实用。每个工具调用（比如查天气、搜网页、执行代码）都生成一个HMAC签名的“收据”，AI改不了。然后系统把AI回答里的每个claim和这些收据做比对，发现claim没有对应收据，或者收据内容对不上，就直接标记“幻觉”。

这个方案的优点：轻量（15毫秒）、可落地、用户能看见证据。比那种让AI自己说“我确定”靠谱多了。

方案B2：多智能体辩论（体验最好）

让几个AI自己吵起来。Trust负责相信，Skeptic负责质疑，Leader负责裁决。针对同一个问题，它们来回辩论几轮，直到达成共识。

这个方案的优点：准确率高，能处理复杂场景。缺点：成本高、速度慢。适合用在那种“答错会出大事”的场景（比如医疗、法律、代码审核）。

方案B3：层级审查流水线（性价比之选）

前面提到的那篇多智能体幻觉缓解论文提供了一个更系统的方案：建一条审查流水线，第一级AI负责生成，第二级负责查事实错误，第三级负责查逻辑漏洞，第四级负责打分评估。每个环节用不同的模型、不同的策略，互相补位。

这个方案的优点：可定制、可扩展。缺点：需要设计复杂的协作机制。

方案C：用户反馈闭环层——让AI学会长记性

这是让AI“越用越懂我”的关键。

当用户指出“你这个是错的”或“这不是我要的”，AI需要把这件事记下来。不是记在临时上下文里，是记在长期记忆里。下次用户问类似的问题，它知道“这个人上次纠正过我，这次要小心”。

Qoder的“提示词增强”功能提供了一个有趣的思路：用户输入一个模糊的指令，AI自动把它扩展成结构清晰、考虑周全的完整提示词。用户可以看到AI是怎么理解自己的，不满意可以撤回，让AI重新理解。这个过程本身就是在训练AI——用户每次撤回、每次修改，都在告诉AI“你理解错了，这样才对”。

华为云AgentArts平台也在做类似的事：用户输入一句话，AI自动生成提示词，用户确认后才能用。这个“确认”环节特别重要，它不是负担，是让用户和AI对齐认知的必经之路。

4.2.5 核心指标

指标类型	具体指标	目标值	统计周期
交互准确率指标	需求理解准确率	≥92%（AI 理解的需求与用户真实需求匹配度）	日统计
幻觉控制指标	幻觉输出率	≤5%（AI 输出错误信息的比例）	日统计
幻觉控制指标	不确定信息标注率	≥100%（所有不确定信息均标注 “仅供参考”）	日统计
用户反馈指标	反馈率	≥20%（使用 AI 交互的用户中，20% 会提交反馈）	周统计
用户反馈指标	反馈满意度	≥80 分（100 分制，用户对 AI 修正、追问的满意度）	月统计
交互效率指标	平均交互轮次	≤3 轮（用户从输入需求到获得满意答案的平均轮次）	周统计

4.2.6评价体系

1. 交互准确率维度（权重 40%）

- 需求理解准确率（60 分）：达标得满分，每低 1% 扣 3 分；
- 交互轮次达标率（40 分）：平均轮次≤3 轮得满分，每增加 0.5 轮扣 5 分。

2. 幻觉控制维度（权重 30%）

- 幻觉输出率（60 分）：达标得满分，每高 1% 扣 12 分；
- 不确定信息标注率（40 分）：达标得满分，每低 1% 扣 4 分。

3. 用户反馈维度（权重 30%）

- 用户反馈率（30 分）：达标得满分，每低 1% 扣 1.5 分；
- 反馈满意度（40 分）：达标得满分，每低 1 分扣 1 分；
- 反馈迭代率（30 分）：用户反馈的问题，每周迭代解决率≥80%，每低 10% 扣 3 分。

4.2.7优先级建议

P0：工具执行收据 + 不确定性表达

前者是最硬核的幻觉检测手段，后者是最低成本的信任何护。两个合起来，能解决80%的“被骗”问题。

P1：意图澄清追问 + 用户反馈闭环

让AI学会追问“人话”，让AI记住用户的纠正。这是从“能用”到“好用”的跨越。

P2：多智能体辩论 + 层级审查流水线

成本高、复杂度高，但准确率也高。适合核心场景先用起来，慢慢铺开。

4.2.8产品价值

对用户：提升 AI 交互的准确率与可信度，减少 “被误导” 的情况，降低交互成本，获得更贴合需求的 AI 服务；

对 AI 产品：提升豆包的用户体验与信任度，减少用户因幻觉、理解偏差导致的流失，强化 AI 产品的核心竞争力；

对后续迭代：通过用户反馈闭环，持续优化 AI 模型，让 AI 更懂用户、更贴合真实场景需求，形成“交互→反馈→优化” 的良性循环。

4.2.9为什么这个方案现在有意义

硅谷那些最前沿的AI公司已经在做这件事了。Adobe的Agentic AI、Citi的Stylus，它们都在强调“提示工程”的重要性，而且已经有了成熟的5C框架（Context背景、Competency能力、Constraints约束、Course of Action行动、Completion Criteria完成标准）。用户不需要自己琢磨这个框架，AI应该帮用户填好。

Salesforce和UIUC的研究团队已经把“用户意图理解”变成了一个可训练、可评估的学术问题。北大把“多智能体辩论”用在了幻觉检测上，而且发了顶会论文。arXiv上那篇NabaOS的论文，直接把工具调用可验证这件事做到了工程可落地。智源研究院也有人在研究用多智能体流水线缓解幻觉。

这些都不是科幻，是已经在发生的事。

国内的产品还在卷“模型参数”“榜单排名”，但用户要的根本不是这个。用户要的是：我说的话你能听懂，你不知道的时候别骗我，我纠正你的时候你能记住。

让AI学会“听懂人话”和“知道自己不知道”——这可能比把参数再做大一倍，更能留住用户。